

MCDI500

PROGRAMACIÓN PARA LA CIENCIA DE DATOS

FASE 4 PROYECTO FINAL

**Posiciones políticas relativas y cohesión partidaria en las votaciones del
proyecto de ley sobre protección de datos personales en Chile**

Nombre integrante/s: Grupo 1

José Ignacio Rodríguez · Yerko Guillermo Gallardo Miranda · Sebastián Eduardo Rojas Araya

Curso: Programación para la Ciencia de Datos · MCDIA500

Docente: Dr. Omar Salinas Silva

Fecha: 4 de octubre de 2026

Repositorio: https://github.com/joserodriguezc/grupo_1_programacion_ciencia_datos

Presentación audiovisual: https://drive.google.com/file/d/1W-GXFWenPeaYA0kOgFc5roDsRaUq6jT6/view?usp=drive_link

I. Portada e Índice

I. Portada e Índice.....	2
II. Introducción y contextualización	4
III. Definición de la problemática y objetivos del proyecto	4
IV. Aplicación de herramientas científicas.....	5
a. Reproducibilidad técnica	5
b. Control de versiones	6
c. Documentación del proceso	6
d. Repositorio GitHub actualizado	6
V. Diseño de soluciones algorítmicas eficientes	6
a. Codificación funcional	6
b. Preprocesamiento y transformación del dataset.....	6
c. Validación técnica y verificación del código	7
d. Eficiencia y optimización	7
e. Diseño estructurado del código	7
f. Notebook final ejecutado y documentado.....	8
VI. Implementación de código modular y robusto.....	8
a. Programación orientada a objetos.....	8
b. Documentación de arquitectura.....	8
VII. Construcción de visualizaciones de datos efectivas	8
a. Preprocesamiento y transformación de datos.....	8
b. Visualizaciones analíticas.....	9
VIII. Metodología del desarrollo técnico	9
a. Validación y reflexión técnica	9
b. Resultados	9
c. Discusión.....	14
d. Conclusiones.....	15
e. Trazabilidad de mejoras	15
IX. Presentación Audiovisual	15
X. Bibliografía	15
Anexo A · Corpus y universos de análisis	17
Anexo B · Modelos y métricas con reglas de interpretación	18
Anexo C · Rendimiento y elección algorítmica	19
Anexo D · Tablas complementarias de resultados	20
Anexo E · Validación de modelos y sensibilidad	21
Anexo F · Arquitectura y reproducción verificable	22
Anexo G · Trazabilidad y comunicación del proyecto.....	23
Anexo H · Integración de fases arquitectura y decisiones de la solución	24

H.1. Aporte de cada fase al sistema final	24
H.2. Arquitectura funcional y flujo operacional.....	25
H.3. Dependencias y aplicación de POO en el núcleo.....	26
H.4. Decisiones relevantes y consecuencias analíticas.....	27
H.5. Relación entre preguntas resultados y evidencia	28

II. Introducción y contextualización

La protección de los datos personales y el derecho a la privacidad son materias centrales para la ética y la gobernanza de datos contemporánea. En Chile, la tramitación legislativa del proyecto de ley sobre protección de datos personales (boletín 11092-07) constituye un caso concreto y verificable para observar cómo los diputados y diputadas, y los partidos políticos a los que pertenecen, se posicionan frente a estas materias.

El problema que aborda este proyecto es, por tanto, la falta de evidencia sistemática y reproducible sobre el posicionamiento ideológico y los patrones de cohesión legislativa que se manifiestan en las votaciones de este proyecto de ley específico. Transformar registros nominales dispersos en indicadores comparables exige un proceso de obtención, integración, procesamiento y análisis que sea a la vez riguroso y auditable, ya que las conclusiones que se deriven de él tendrán implicancias sobre cómo se interpreta el comportamiento de actores políticos concretos.

Existe una justificación sustantiva para este análisis: la protección de datos personales no es solo una materia técnico-legal, sino un asunto de ética pública en el que el comportamiento legislativo constituye evidencia relevante sobre cómo el sistema político chileno procesa los derechos digitales de la ciudadanía. Conocer si el posicionamiento de diputadas, diputados y partidos frente a este boletín es estable o errático, y si la cohesión interna de las bancadas se mantiene o se fragmenta, permite aportar al escrutinio ciudadano y académico sobre la construcción de políticas de protección de datos.

El informe integra el desarrollo completo de F1–F4. F1 definió el problema, las cuatro preguntas y el entorno reproducible; F2 construyó la primera cadena de obtención, exploración, limpieza e integración; F3 consolidó ese flujo mediante módulos, objetos, validaciones y mediciones de eficiencia; F4 convirtió la tabla validada en posiciones relativas, indicadores partidarios y contrastes de robustez. La solución resultante es un sistema de procesamiento y análisis descriptivo de votaciones con afiliación histórica, salidas verificables y comunicación de resultados. Sus tres hallazgos son: dos alineamientos predominantes en esta agenda, posiciones partidarias centrales que pueden ocultar heterogeneidad y unidad de voto con matices de disenso. El Anexo H vincula cada fase con su aporte a la solución final.

La justificación técnica de abordar esta problemática mediante programación, en lugar de una revisión manual, radica en el volumen y la estructura de la evidencia: 15 votaciones, 157 diputados en el catálogo y 1.993 votos nominales que deben integrarse con militancias sujetas a cambios. La diferencia entre catálogo y universo observado es relevante: 151 personas registran decisiones en el corte. Un pipeline reproducible permite auditar desde el XML fuente hasta cada indicador; el Anexo A delimita los universos y el Anexo F identifica la evidencia de validación.

III. Definición de la problemática y objetivos del proyecto

La problemática que aborda este proyecto es el déficit de transparencia sobre el comportamiento legislativo real en materia de protección de datos en Chile: aunque el sentido de cada voto es público, la posición política que ese voto efectivamente expresa no resulta directamente accesible desde los registros de la Cámara. No se trata de falta de acceso al dato crudo, sino de falta de acceso a su significado político. Superar este déficit exige transformar registros nominales dispersos en un proceso reproducible y auditable que produzca indicadores de posición ideológica relativa, estabilidad individual y cohesión partidaria. El posicionamiento estimado corresponde exclusivamente a esta agenda legislativa; no permite determinar por sí solo el compromiso general de un actor con la privacidad.

Preguntas de investigación:

- **P1.** ¿Qué posiciones políticas relativas presentan las diputadas y los diputados a partir de sus patrones de votación durante la tramitación del proyecto de ley?
- **P2.** ¿Qué grado de estabilidad o variabilidad presenta el comportamiento individual de las diputadas y los diputados a lo largo de las votaciones analizadas?
- **P3.** ¿Qué posiciones políticas relativas presentan los partidos políticos a partir del comportamiento de sus integrantes?

- **P4.** ¿Qué grado de cohesión o dispersión presentan los partidos políticos durante la tramitación del proyecto de ley?

Objetivo general. Analizar las posiciones políticas relativas y la estabilidad del comportamiento legislativo de las diputadas y los diputados, así como las posiciones políticas relativas y el grado de cohesión de los partidos políticos, a partir de todas las votaciones nominales asociadas al proyecto de ley sobre protección de datos personales en la Cámara de Diputadas y Diputados de Chile.

Objetivos específicos. Obtener el catálogo completo y los detalles nominales; identificar períodos y militancia vigente; explorar, limpiar, normalizar e integrar diferenciando categorías y condiciones registradas; construir la big table y las matrices para B-Call y clustering; estimar posiciones y estabilidad individual; estimar posiciones y cohesión partidaria; validar datos y consistencia metodológica; comunicar mediante visualizaciones y artefactos reproducibles.

Alcance, restricciones y supuestos. Se analiza el corte de 15 votaciones en sala, catorce del 08-05-2023 y una del 26-08-2024, con clave `diputado_id-votacion_id` y partido vigente en cada fecha. Se supone correspondencia entre códigos oficiales y etiquetas, y que las reglas temporales permiten integrar afiliaciones. Se conservan advertencias de calidad y razones de exclusión. Sin padrón de elegibilidad, una celda sin registro no demuestra inasistencia. La estabilidad de P2 se interpreta entre decisiones observadas; la concentración temporal impide estimar trayectorias. Tampoco se contrastan programas partidarios ni se generaliza el eje a otras agendas. El Anexo A detalla qué universo usa cada método.

IV. Aplicación de herramientas científicas

El proyecto integra herramientas de adquisición, procesamiento, análisis y visualización con mecanismos de validación y reproducibilidad. Zeep permite consultar los servicios SOAP de la Cámara; lxml serializa las respuestas XML y ElementTree permite interpretar y recorrer los archivos conservados. pandas se utiliza para conversión de tipos, normalización, cruces, agrupación y asignación histórica de militancias; NumPy sustenta las operaciones matriciales, distancias y la descomposición SVD del PCA mediante `numpy.linalg.svd`. SciPy aporta el clustering jerárquico y sus procedimientos de enlace, mientras Matplotlib y Seaborn permiten visualizar los resultados. JupyterLab e ipykernel reúnen código, salidas y explicación en notebooks.

La calidad y reproducibilidad se apoyan en pytest para pruebas unitarias, de integración y de ejecución de notebooks; nbformat y nbclient permiten leer y ejecutar estos últimos de forma automatizada. Ruff realiza análisis estático del código, y uv administra el entorno y las dependencias mediante el archivo de bloqueo `uv.lock`. Git registra los cambios y GitHub organiza la colaboración mediante ramas y pull requests; GitHub Actions automatiza las comprobaciones de identidad, análisis estático y pruebas. En F3, `time.perf_counter` y `tracemalloc` permiten medir tiempos de ejecución y memoria administrada por Python, mientras las huellas SHA-256 registran la identidad de entradas y salidas para verificar su integridad. El procesamiento tabular sigue a McKinney (2022), y la organización mediante objetos e interfaces se fundamenta en Ramalho (2022). Esta combinación conecta cada resultado con sus datos, transformaciones y controles, facilitando su revisión y reproducción.

a. Reproducibilidad técnica

`pyproject.toml` exige Python ≥ 3.12 y < 3.13 ; `uv.lock` bloquea dependencias y `uv` crea `.venv`. Los resultados B-Call registran Python 3.12.13, pandas 3.0.5 y NumPy 2.5.3; la CI de cierre usa Python 3.12.3 y pytest 9.1.1. La instalación se ejecuta con `uv sync --locked --group dev`. Los XML permiten reprocesamiento sin red; las pruebas de notebooks operan en copias temporales. Los manifiestos registran commit y SHA-256 del corte y de salidas. La reproducibilidad se acredita en los entornos registrados, no mediante una garantía de compatibilidad con cualquier equipo. Los comandos completos y límites están en el Anexo F.

b. Control de versiones

Git registra la evolución del proyecto mediante ramas por componente y pull requests hacia main. La referencia técnica revisada es aad911245e54; los resultados conservan el corte F3 identificado en su manifiesto y la evidencia de CI de cierre indicada en el Anexo F. Esta separación permite distinguir versión del código, identidad del dataset y ejecución de pruebas. .mailmap y la comprobación de identidad vinculan las contribuciones con sus autores. El Anexo G relaciona observación, acción, commit e impacto, sin equiparar cantidad de commits con calidad del aporte.

c. Documentación del proceso

La documentación se organiza por nivel: el informe explica la solución, su arquitectura y las decisiones que afectan la interpretación; los notebooks desarrollan cada bloque con código, resultados y lecturas; docstrings, pruebas y contratos contienen el detalle verificable. analisis.toml y decisiones_metodologicas.json registran parámetros y fundamentos. Las exclusiones conservan códigos de razón y la conciliación explica diferencias de universo. El Anexo H sintetiza las decisiones estructurales; el repositorio conserva sus implementaciones y diagnósticos.

d. Repositorio GitHub actualizado

El repositorio integra los datos, notebooks, código y documentación de las fases F1–F4. F4 contiene seis notebooks, módulos de análisis, contratos de datos, figuras y manifiestos de reproducibilidad. El README describe la arquitectura final, la organización de archivos y las instrucciones de instalación y ejecución. La integración continua en GitHub Actions incorpora Ruff, pruebas automatizadas y ejecución de notebooks. Las carpetas, los commits y los registros de ejecución permiten rastrear las entradas, transformaciones y resultados del proyecto. El Anexo F complementa esta documentación con el procedimiento de reproducción del análisis.

V. Diseño de soluciones algorítmicas eficientes

La solución combina contratos de entrada, operaciones tabulares y verificación de equivalencia antes de optimizar. La eficiencia se decide mediante experimentos controlados, considerando tiempo y memoria, y preservando el significado de votos y afiliaciones.

a. Codificación funcional

La solución separa la adquisición de fuentes, preparación de tablas, integración temporal, construcción de matrices y análisis. construir_big_table() recibe detalle de votos, proyecto, diputados y militancias; entrega la tabla analítica y diagnósticos de asignación. asignar_vectorizado() devuelve diagnósticos y asignaciones sin modificar las entradas. Los modelos reciben matrices y parámetros explícitos, y producen resultados y razones de no estimabilidad. En F4, pipeline.py coordina las dependencias de los módulos; las salidas B-Call son producidas por F4_02 y constituyen un prerrequisito de comparación y universo. El Anexo H muestra esta arquitectura y el Anexo F sus interfaces de entrada y salida.

b. Preprocesamiento y transformación del dataset

La cadena raw–interim–processed conserva el XML original y separa representación, validación e integración. La normalización de textos y códigos evita categorías equivalentes escritas de manera distinta; el casting de fechas e identificadores permite cruces consistentes; los controles de claves y referencias previenen duplicaciones o vínculos inexistentes. La militancia se asigna a la fecha del voto mediante intervalos cerrados y término abierto cuando la fecha final es nula. Los estados OK, SIN_MILITANCIA y AMBIGUA hacen explícitas las situaciones resueltas o indeterminadas. F3 conserva la equivalencia con F2: catálogo de 157 diputados, 407 militancias, 15 votaciones y tabla analítica de 1.993 filas por 34 columnas.

F4 construye vistas nominal (Sí/No/Abstención), ternaria (1/-1/0) y binaria (1/0/NA), cada una adecuada al estimando: categorías para acuerdo y cohesión, valores ternarios para B-Call/PCA y contraste binario para Sí/No. La abstención es una decisión observada; no equivale a un registro faltante. Las 272 celdas sin registro permanecen NA y no se imputan: convertirlas en cero produciría acuerdos ficticios o posiciones artificialmente centrales. El corte no contiene dispensas registradas y no permite identificar ausencias. Los conteos se concilian con la fuente antes de modelar; la máscara conserva qué decisiones fueron observadas.

c. Validación técnica y verificación del código

Las pruebas cubren casos normales, fronteras de vigencia, afiliación ambigua, claves duplicadas, códigos desconocidos, cero covotos, varianza nula y participación exactamente en el umbral. Se verifica equivalencia entre F2/F3 y entre asignación iterativa/vectorizada, además de las salidas intermedias de F4. El cierre de CI aprobó 394 pruebas rápidas y 48 pruebas de notebooks, con Ruff e identidad Git también aprobados. La auditoría registra 14 controles OK, 8 advertencias y 0 errores; las 23 conciliaciones incluyen 20 coincidencias, 3 diferencias explicadas y ningún pendiente. El Anexo F identifica ejecución y alcance de esta evidencia.

d. Eficiencia y optimización

F3 mide con `perf_counter`, cinco repeticiones y un calentamiento, usando mediana temporal. La memoria se mide en ejecuciones separadas con `tracemalloc` para no distorsionar los tiempos (Python Software Foundation, s. f.-a, s. f.-b). Se excluyen red y preparación de fixtures. Las escalas sintéticas $1\times/5\times/10\times/100\times$ replican votos con IDs nuevos: comparan costo computacional, no agregan evidencia política. La asignación vectorizada tarda 0,008124 s frente a 1,061622 s en $1\times$; en $100\times$, 0,578368 s frente a 92,010762 s. Los cocientes entre $130,68\times$ y $205,96\times$ justifican su elección con igual salida, en el entorno original de medición (Anexo C).

El benchmark XML compara recorridos iterativo y recursivo sobre los mismos nodos ya parseados con `ElementTree`. Los cocientes iterativo/recursivo son 1,106, 1,002 y 0,994 en $1\times/5\times/10\times$; no muestran ventaja recursiva sostenida. Se conserva el recorrido directo. La recursión por mitades reduce profundidad a $O(\log n)$, pero copias y concatenaciones elevan el trabajo a $O(n \log n)$; el recorrido directo cuesta $O(n)$. La memoria de salida es $O(n)$.

El análisis asintótico complementa las mediciones: el iterativo puede revisar hasta M militancias para N votos; el cruce vectorizado crea C candidatos y su filtro temporal cuesta $O(C)$, con memoria proporcional a C y peor caso $C \approx NM$. La aceleración empírica no acredita una cota asintótica distinta. Las distancias entre D diputados y V decisiones cuestan $O(D^2V)$ y su matriz $O(D^2)$ de almacenamiento. La elección de operaciones vectorizadas reduce sobrecostos, pero exige controlar la expansión de candidatos y el componente cuadrático (Tabla N° 06).

e. Diseño estructurado del código

El código se organiza en módulos con responsabilidades delimitadas. En F3, los extractores, modelos de datos, validadores, transformadores e integradores separan la adquisición, el control de calidad y la construcción de la tabla analítica. En F4, módulos específicos realizan la codificación, construcción de matrices, estimación de posiciones, cálculo de cohesión y afinidad, análisis de sensibilidad y visualización. Esta división favorece la alta cohesión de cada componente y reduce el acoplamiento mediante interfaces y contratos compartidos.

El flujo conecta fuentes SOAP/XML, tablas interim, datos processed, integración histórica y matrices analíticas. Los contratos y validaciones verifican la transición entre etapas; los manifiestos identifican sus entradas y salidas. La división funcional incluye un recorrido recursivo por mitades con caso base de hasta 32 nodos, comparado con el recorrido iterativo; se conserva este último en producción según la evidencia de rendimiento. La extensibilidad se apoya en interfaces específicas y funciones intercambiables, mientras el procesamiento masivo permanece en DataFrames. El Anexo H distingue la arquitectura funcional de las dependencias del núcleo; el Anexo C declara los límites temporales y espaciales.

f. Notebook final ejecutado y documentado

La evidencia ejecutable conserva el orden F1–F4: F1_Definición documenta el caso; F2_01–04 obtienen, exploran, depuran e integran; F3_01 verifica equivalencia y eficiencia; F4_01–06 desarrollan cobertura, B-Call, posición/afinidad, clustering/PCA, cohesión y comunicación. F4_06 integra las respuestas analíticas y las vincula con las cuatro preguntas; F3_01 conserva la evidencia de la construcción del núcleo. Las pruebas ejecutan los seis notebooks F4 en copias temporales y comparan las tablas con las salidas versionadas, con tolerancia relativa $1e-9$ para diferencias numéricas de SVD. El Anexo H permite recorrer esta progresión y localizar el detalle en el repositorio.

VI. Implementación de código modular y robusto

La arquitectura combina módulos de transformación tabular con objetos que concentran reglas de construcción, validación y estimación. F3 refactoriza la cadena funcional de F2 sin alterar sus salidas; F4 añade modelos y objetos de resultados para responder las preguntas. Los notebooks orquestan y comunican, mientras las reglas de dominio se mantienen en módulos. Los errores y valores no estimables se registran con razones explícitas para que un resultado ausente no se confunda con cero.

a. Programación orientada a objetos

ExtractorBase define una interfaz abstracta y una plantilla común de descarga, procesamiento y persistencia; sus cuatro extractores especializados implementan consultas y parseo, y `_post_procesar()` actúa como gancho. La herencia y el polimorfismo permiten reutilizar ese contrato. Cinco dataclasses inmutables, derivadas de `ModeloInterim`, validan registros y controlan su serialización: aplican objetos de valor en el límite XML–interim. TransformadorDataset utiliza validadores de tablas e integración, separando operaciones y controles. Los asignadores iterativo y vectorizado son funciones intercambiables con iguales entradas y salidas, sin atribuirles una jerarquía de clases Strategy. En F4, `ModeloBCall`, `PCASVD` y `AgrupamientoDiputados` separan parámetros, cálculo y resultados. La Imagen N° 07 del Anexo H muestra estas dependencias.

b. Documentación de arquitectura

La arquitectura distingue tres planos: datos (raw, interim, processed y resultados), lógica (extractores, validadores, integrador y modelos) y orquestación/documentación (notebooks, pipeline y manifiestos). `contratos.py` centraliza rutas, productores, esquemas, claves y códigos de razón; `pipeline.py` ordena dependencias; `exportacion.py` verifica salidas y registra hashes. Esta separación hace rastreable qué componente produjo cada resultado. Template Method reutiliza el flujo de extracción, aunque las fuentes con varias entradas o salidas especializan parte de la plantilla; generalizar sus ganchos es una proyección de diseño. Los Anexos F y H incorporan interfaces, fragmento de código y diagramas funcional y de dependencias.

VII. Construcción de visualizaciones de datos efectivas

Las visualizaciones se seleccionan por su contribución a las preguntas. El relato parte del corpus, distingue posición y variabilidad individual, contrasta la referencia externa y relaciona posición partidaria con heterogeneidad y cohesión. Cada figura conserva título de hallazgo, universo, ejes, leyendas, fuente y una lectura de cuatro componentes. Las cinco figuras de resultados se presentan en VIII.b; los diagramas de solución se incluyen en el Anexo H.

a. Preprocesamiento y transformación de datos

Se grafican salidas conciliadas y se declara el universo de cada panel. Las dos decisiones unánimes se excluyen del escalamiento por varianza nula, pero se conservan para cohesión y afinidad. El plano d1–d2 representa 135 personas; una de las 136 con d1 carece de d2 por tener una sola decisión informativa. Las coordenadas repetidas se representan por áreas proporcionales sin jitter ni modificación de puntajes. Los resúmenes partidarios respetan la afiliación histórica y excluyen IND como supuesto partido.

b. Visualizaciones analíticas

La Imagen N° 01 sitúa unanimidad y desacuerdo en el corpus; la N° 02 muestra posición y variabilidad individual; la N° 03 contrasta los grupos externos recalculados; la N° 04 compara posición agregada, mediana y dispersión partidaria; y la N° 05 integra cohesión y desacuerdo. Las burbujas hacen visibles coordenadas compartidas y las densidades suavizan patrones discretos. Los resúmenes partidarios se complementan con dispersión y desacuerdo para evitar interpretar una cifra central o una mediana como comportamiento uniforme.

VIII. Metodología del desarrollo técnico

La metodología articula los entregables de las cuatro fases: definición del caso, integración de fuentes, consolidación del núcleo y análisis descriptivo. El corte F3 se identifica por hash; su estructura se audita antes de codificar; cada método declara universo y reglas; las salidas se contrastan y concilian antes de comunicar. La configuración 0.8.1 registra protocolo y puertas de universos y clasificación de resultados aprobados. B-Call agrupa antes de aplicar participación >10 % sobre las 15 columnas; el pivote 815 orienta el lado positivo. Sin padrón verificable no se aplica como filtro individual un umbral general de cobertura del 60 %. La Tabla N° 14 del Anexo H explica las decisiones y sus consecuencias.

B-Call se traduce a Python desde el núcleo R de referencia 4c2e2a9 (Toro-Maureira et al., 2025): estandariza con desviación muestral, orienta por grupos y obtiene media d1 y desviación d2. El escenario externo proporciona dos grupos y recalcula puntajes sobre su universo; no sustituye etiquetas de la solución automática. La posición partidaria promedia por partido/votación y después entre votaciones con igual peso. Al conserva abstenciones, Rice las omite y la entropía contrasta la concentración de opciones (Hix et al., 2005; Rice, 1925; Shannon, 1948). Fórmulas, mínimos y niveles están en el Anexo B.

a. Validación y reflexión técnica

La validación combina contratos, equivalencia histórica, pruebas ejecutables, universos explícitos y sensibilidad. El contraste jerárquico usa Hamming nominal y enlace promedio sobre 135 diputados con cobertura ≥ 80 % de las 13 decisiones informativas. PCA/SVD centra la matriz ternaria sin escalar y conserva 107 casos completos, excluyendo 44 sin imputación. PC1 reúne 85,70 % de la varianza y PC2 7,24 %. Las comparaciones se realizan sobre personas comunes, sin tratar 107, 135 y 136 como un mismo universo.


Clustering coincide con B-Call (ARI=1; cero discrepancias sobre 135 personas); PC1 alineada se asocia con d1 (Pearson=0,999880; Spearman=0,998512, 107 comunes). Es convergencia interna sobre los mismos votos, no prueba independiente de ideología. Los 25 pivotes elegibles conservan el eje. Al retirar una votación, el cambio máximo de d1 es 0,185 y se registran seis inversiones de signo; el ARI mínimo es 0,970. Al retirar el bloque de nueve disposiciones 20629–20637, el ARI cae a 0,461 y cambian 17 grupos. La robustez a omisiones aisladas no implica independencia de la agenda (Anexo E).

El cotejo histórico externo registra 82,69 % de concordancia sobre 1.479 filas diputado–votación. El escenario con grupos externos admite 108 diputados con d1 y representa 107 con ambas dimensiones. La clasificación externa participa en la orientación y estandarización de este escenario. Retirar PDG/Demócratas eleva la concordancia a 84,37 % sobre un universo diferente; este cambio no acredita mayor exactitud ideológica. Las discrepancias se conservan y se interpretan como contraste entre referencia partidaria y comportamiento observado.

b. Resultados

Contexto del corpus. Dos decisiones fueron unánimes y trece registraron diferencias. Catorce de las quince votaciones se concentran en el 8 de mayo de 2023; la decisión restante, del 26 de agosto de 2024, corresponde a la Comisión Mixta. El predominio de votos afirmativos convive con divisiones sobre disposiciones particulares. La mayor presencia de abstenciones en la última decisión no permite atribuir un cambio al tiempo, porque también cambia lo sometido a votación.

Imagen N° 01. La unanimidad en dos decisiones convive con disenso en otras trece



Fuente: proyecto_ley_procesado.csv (F3), totales oficiales de la votación.


Elaboración propia en base a proyecto_ley_procesado.csv (F3) y la figura 01_votaciones_corpus.png de F4_06.

Qué muestra: La figura presenta los votos afirmativos, negativos y las abstenciones en las quince votaciones del corpus. Dos decisiones fueron unánimes y trece registraron diferencias. Catorce votaciones corresponden a la sesión del 8 de mayo de 2023; la restante, del 26 de agosto de 2024, corresponde a la Comisión Mixta. **Qué infiero:** El predominio de votos afirmativos expresa acuerdos mayoritarios, pero no un consenso uniforme sobre todas las disposiciones del proyecto. La oposición registrada en trece decisiones muestra que el respaldo a esta agenda convivió con controversias específicas. Por ello, el comportamiento legislativo debe analizarse por disposición: una mayoría favorable no implica que todos los actores compartan una misma posición frente al conjunto del proyecto. **Qué límite tiene:** Las votaciones corresponden a contenidos distintos y se concentran principalmente en una sola sesión. La mayor presencia de abstenciones en la decisión de 2024 no permite concluir que hubo un cambio temporal de posición, porque también cambia lo sometido a votación. Asimismo, los totales de esta figura no identifican qué diputados o partidos coinciden entre decisiones. **Cómo aporta al relato:** Delimita la evidencia con la que se responden las cuatro preguntas de investigación. Las trece decisiones no unánimes permiten distinguir patrones de posición individual y partidaria; las dos unánimes se conservan para estudiar cohesión y afinidad, aunque se excluyen del escalamiento de posiciones por su varianza nula.

Imagen N° 02. Dos bloques predominan y las posiciones intermedias combinan decisiones de ambos lados

Dos bloques separados: 94 diputados en el lado L, 42 en el R y solo 20 intermedios


135 diputados con d1 y d2 estimables · 33 posiciones distintas



Elaboración propia en base a los datos abiertos de la Cámara de Diputadas y Diputados de Chile y las salidas versionadas de F4.

Qué muestra: La figura relaciona la posición relativa individual (d1, eje horizontal) con la variabilidad de los votos estandarizados (d2, eje vertical). Cada burbuja representa una coordenada y su área indica cuántos diputados la comparten. B-Call estima d1 para 136 personas: 94 en L y 42 en R. El gráfico representa 135 con ambas dimensiones —93 en L y 42 en R—, distribuidas en 33 coordenadas; una persona queda fuera del plano porque d2 no es estimable. Las medianas de d2 son 0,095 en L y 0,321 en R. **Qué infiero:** Predominan dos agrupamientos con patrones de votación compartidos: cuatro coordenadas reúnen 90 personas, aproximadamente el 67 % del plano. Las posiciones próximas al centro requieren una lectura distinta: de las veinte personas con $|d1| < 0,5$, diecinueve combinan votos afirmativos y negativos entre disposiciones. Su ubicación central puede resumir decisiones contrapuestas y no demuestra moderación política. La mayor mediana de d2 en R indica mayor variabilidad de los votos estandarizados en ese agrupamiento; no acredita, por sí sola, cambios de bloque ni menor cohesión partidaria. **Qué límite tiene:** El eje se construye con trece votaciones informativas de este proyecto y describe posiciones relativas a esta agenda; no identifica motivaciones ni una ideología permanente. Una persona que mantiene la misma opción puede presentar d2 positivo, porque cada votación se estandariza según su propia distribución. Además, las densidades suavizan patrones discretos: las burbujas representan las coordenadas efectivamente observadas. **Cómo aporta al relato.** Responde P1 al identificar los principales agrupamientos y las posiciones intermedias, y aporta a P2 al describir la variabilidad individual entre decisiones. La lectura conjunta de ambos ejes permite distinguir posición y consistencia del voto, sin equipararlas con ideología general, moderación o disciplina partidaria.

Imagen N° 03. Algunos diputados clasificados de derecha comparten posiciones con la izquierda




Elaboración propia en base a *diputados_externo.csv*, *universo_externo.csv* y *posicion_variabilidad_bcall_manual.png* de F4_02.

Qué muestra. La figura presenta las posiciones y la variabilidad individual de B-Call utilizando grupos externos definidos mediante una clasificación política de referencia. El plano contiene 107 personas con ambas dimensiones estimables: 52 clasificadas de izquierda y 55 de derecha, distribuidas en 29 coordenadas. Una misma coordenada reúne 43 diputados: 40 de izquierda y 3 de derecha. Las burbujas permiten identificar posiciones compartidas entre personas de distinta clasificación. **Qué infiero.** La clasificación política de referencia no se traduce en una separación uniforme del comportamiento legislativo en este proyecto. Algunos diputados clasificados de derecha presentan posiciones coincidentes o próximas a las de integrantes de izquierda; en la coordenada compartida por 43 personas, la coincidencia es exacta en ambas dimensiones. Este resultado muestra que los alineamientos observados en la agenda de protección de datos pueden atravesar la división izquierda–derecha. La pertenencia a un sector político, por tanto, no basta para anticipar la posición de cada diputado frente a estas disposiciones. **Qué límite tiene.** La figura representa personas y no permite atribuir este comportamiento a partidos completos ni concluir que existe una alianza, un cambio ideológico o motivaciones compartidas. Las etiquetas externas constituyen una referencia metodológica, no una medición independiente de la ideología individual. Además, este escenario recalcula los puntajes sobre su propio universo: no equivale a cambiar los colores del gráfico automático ni permite interpretar las diferencias entre ambos planos como desplazamientos políticos. **Cómo aporta al relato.** Complementa la respuesta a P1 y contextualiza P2 al contrastar clasificación política de referencia con posición y variabilidad observadas. Refuerza la interpretación de los agrupamientos como alineamientos relativos a este proyecto y permite reconocer coincidencias de voto entre sectores que una lectura basada exclusivamente en etiquetas partidarias podría pasar por alto.

Imagen N° 04. El centro de RN y PDG reúne posiciones contrapuestas dentro de sus bancadas

9 partidos forman un bloque compacto en el lado L; PDG y RN tienen integrantes en ambos lados

14 partidos con P_p publicable; IND se calcula pero no se publica




Fuente: posicion_partidaria.csv. P_p usa el partido vigente en cada votación; la mediana y el RIQ de d1 describen a sus integrantes.

Elaboración propia en base a los datos abiertos de la Cámara de Diputadas y Diputados de Chile y las salidas versionadas de F4.

Qué muestra. La figura compara la posición agregada de cada partido (P_p), la mediana de las posiciones individuales (d1) y su dispersión, medida mediante el rango intercuartílico (RIQ). Catorce partidos cumplen los criterios de publicación: nueve convergen en L, mientras UDI y Republicanos (PREP) se ubican en R. RN (P_p=0,171), PDG (-0,030) y EVOP (-0,074) presentan posiciones agregadas próximas al centro. Sin embargo, su dispersión es diferente: el RIQ alcanza 1,172 en RN, 0,952 en PDG y 0,173 en EVOP. **Qué infiero.** Una posición partidaria central puede surgir de integrantes con posiciones contrapuestas, sin expresar una postura moderada compartida. En RN y PDG, la presencia de diputados de ambos lados del eje y la elevada dispersión muestran que el agregado resume una bancada heterogénea. EVOP presenta menor dispersión, por lo que su proximidad al centro requiere una interpretación distinta. La figura permite distinguir entre partidos cuyos integrantes convergen en posiciones similares y partidos cuyo valor agregado reúne diferencias internas que una cifra única podría ocultar. **Qué límite tiene.** P_p promedia primero a los integrantes de cada partido por votación y luego las votaciones admitidas con igual peso; la mediana de d1 resume posiciones individuales y, por ello, ambas medidas pueden diferir. Los resultados dependen de la composición histórica de las bancadas y de las decisiones incluidas: no identifican facciones organizadas ni una ideología general. Siete partidos no cumplen los mínimos de publicación y la categoría IND se excluye del agregado partidario porque no constituye un partido homogéneo. **Cómo aporta al relato.** Responde P3 al caracterizar las posiciones relativas de los partidos y mostrar cuánto representan esas posiciones a sus integrantes. La lectura conjunta de agregado, mediana y dispersión evita equiparar centralidad con moderación y prepara el análisis de P4: la heterogeneidad de posiciones debe contrastarse con la cohesión del voto, porque son dimensiones relacionadas, pero diferentes.

Imagen N° 05. El disenso se concentra en RN y PDG y las abstenciones distinguen a UDI



Fuente: resumen_cohesion.csv y hamming_partidos.csv. Solo partidos con resumen publicable (al menos 2 votaciones con 2 o más decisiones); IND no es un partido.

Elaboración propia en base a los datos abiertos de la Cámara de Diputadas y Diputados de Chile y las salidas versionadas de F4.

Qué muestra. La figura compara cuatro indicadores para catorce partidos con resumen admisible: las medianas del Agreement Index (AI), Rice y cohesión entrópica, junto con el desacuerdo intrapartido. RN y PDG presentan medianas AI de 0,559 y 0,500, respectivamente, y desacuerdos intrapartido de 0,35 y 0,55. UDI registra una mediana AI de 0,917 y Rice de 1. EVOP combina una mediana AI de 1 con un desacuerdo intrapartido de 0,20. Diez partidos presentan unidad en las celdas admitidas y comparaciones observadas.

Qué infiero. El desacuerdo se distribuye de manera desigual entre las bancadas. RN y PDG muestran menor unidad de voto, lo que complementa la heterogeneidad de posiciones observada en la figura anterior. En UDI, la diferencia entre AI y Rice revela un matiz sustantivo: puede existir unidad entre quienes votan Sí o No y, simultáneamente, diferencias al considerar las abstenciones. EVOP muestra que una mediana máxima puede coexistir con episodios de disenso. Por ello, la cohesión requiere combinar indicadores y examinar decisiones concretas, evitando interpretar un único resumen como unanimidad permanente. **Qué límite tiene.** Los indicadores consideran opciones y denominadores distintos: Rice excluye abstenciones, mientras AI y la cohesión entrópica las incorporan; el desacuerdo intrapartido compara decisiones compartidas entre pares de diputados. Las medianas pueden ocultar episodios puntuales y las bancadas pequeñas ofrecen menos comparaciones. Los resultados describen unidad observada en este corpus y no permiten atribuirle a disciplina impuesta por las dirigencias, acuerdos internos o motivaciones comunes.

Cómo aporta al relato. Responde P4 al identificar diferencias de cohesión y dispersión entre partidos, y completa la respuesta a P3 al distinguir posición partidaria de unidad de voto. Una bancada puede compartir un lado del eje y discrepar en disposiciones específicas; del mismo modo, una posición agregada próxima al centro puede coexistir con desacuerdos internos. Esta distinción permite interpretar conjuntamente los alineamientos políticos y la forma en que las bancadas votan en este proyecto.

c. Discusión

Los resultados son consistentes con la expectativa inicial de encontrar posiciones relativas y cohesión diferenciada. Las dos decisiones unánimes coexisten con desacuerdo en otras trece; la estructura depende de disposiciones concretas, especialmente del bloque 20629–20637. El contraste externo aporta una lectura política adicional: algunos diputados clasificados de derecha comparten posiciones y patrones con integrantes de izquierda en esta agenda. Esa proximidad atraviesa la clasificación de referencia, pero no demuestra cambio ideológico, alianza ni comportamiento uniforme de partidos completos. La posición central de RN y PDG reúne perfiles contrapuestos y debe leerse junto con su dispersión.

La respuesta a P2 queda delimitada por la muestra: catorce votaciones ocurrieron en una sesión y solo una en otra fecha. No hay secuencia suficiente para separar diferencias de contenido de cambios temporales; se describe consistencia entre disposiciones, no estabilidad ideológica durante toda la tramitación. Los registros faltantes tampoco identifican asistencia. La ausencia de padrón verificable obliga a informar coberturas observadas y excluye inferencias sobre inasistencia o compromiso. La validación técnica asegura consistencia del cálculo con las reglas, pero no elimina estas restricciones sustantivas.

La unidad observada presenta matices. La diferencia Rice–AI en UDI muestra que las abstenciones importan; EVOP evidencia que una mediana máxima puede coexistir con disenso puntual. Los tamaños de bancada y los mínimos de publicación también influyen: exigir tres decisiones cambia la admisibilidad de cuatro resúmenes, aunque las medianas comparables permanecen iguales. La convergencia entre B-Call, clustering y PCA es evidencia interna porque comparten los votos; la clasificación externa es una referencia metodológica y no una verdad ideológica observada. El principal riesgo interpretativo es convertir agregados, coincidencias o resúmenes de unidad en explicaciones de motivación o disciplina.

d. Conclusiones

La solución integra F1–F4 y convierte registros oficiales en evidencia descriptiva trazable. Responde P1/P2 con posición y variabilidad individual, y P3/P4 con posición partidaria, heterogeneidad y cohesión. Tres conclusiones sostienen el relato: predominan dos alineamientos de esta agenda, con coincidencias de algunos diputados de derecha con la izquierda según la referencia externa; los agregados centrales de RN y PDG pueden ocultar posiciones contrapuestas; y la unidad de voto requiere considerar abstenciones y episodios de disenso. En ingeniería, F3 conserva equivalencia con F2 y mejora el tiempo de asignación mediante vectorización; F4 incorpora contratos, universos, conciliación y sensibilidad. Esta base permite auditar y reutilizar el proceso.

Las proyecciones derivan de los límites observados: ampliar proyectos, sesiones y períodos para evaluar la persistencia de los alineamientos; vincular votos con disposiciones y debates e incorporar elegibilidad para interpretar participación; y comparar codificaciones y métodos sobre universos comunes, informando tamaño de bancada y sensibilidad a la agenda. En ingeniería, corresponde controlar la expansión del cruce temporal, complementar tracemalloc con memoria nativa y generalizar ganchos de extracción múltiple. Estas extensiones permiten investigar generalización y evolución temporal que el corpus actual no identifica; los resultados presentes no atribuyen causalidad, motivaciones ni una ideología general.

e. Trazabilidad de mejoras

El Anexo G vincula necesidades y recomendaciones con acciones, commits e impacto. Documenta equivalencia F2/F3, asignación vectorizada, comparación de recorridos XML, tolerancia de SVD, tratamiento de IND y contratos del pipeline. La recomendación docente sobre títulos de hallazgo y cuatro componentes de lectura se incorpora en las cinco figuras de resultados y en su discusión. La arquitectura y las decisiones se sintetizan en el Anexo H, mientras el historial Git conserva la evidencia de implementación y revisión.

IX. Presentación Audiovisual

La presentación audiovisual articula problema, preguntas, arquitectura funcional, decisiones relevantes, hallazgos y conclusiones. La presentación se encuentra disponible en: https://drive.google.com/file/d/1W-GXFWenPeaYA0kOgFc5roDsRaUq6jT6/view?usp=drive_link

X. Bibliografía

Cámara de Diputadas y Diputados de Chile. (s. f.). *Datos abiertos*. <https://www.camara.cl/transparencia/datosAbiertos.aspx>

Grupo 1. (2026a). *Avance del proyecto fases 1 y 2* [Informe académico, Universidad Andrés Bello].

Grupo 1. (2026b). *Avance del proyecto fase 3 semana 2* [Informe académico, Universidad Andrés Bello].

- Grupo 1. (2026c). Proyecto de Programación para la Ciencia de Datos [Repositorio de software, versión aad911245e54]. https://github.com/joserodriguezc/grupo_1_programacion_ciencia_datos
- Hix, S., Noury, A., & Roland, G. (2005). Power to the parties: Cohesion and competition in the European Parliament, 1979–2001. *British Journal of Political Science*, 35(2), 209–234. <https://doi.org/10.1017/S0007123405000128>
- McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3.^a ed.). O'Reilly Media.
- pandas development team. (s. f.). *Merge, join, concatenate and compare*. pandas documentation. https://pandas.pydata.org/docs/user_guide/merging.html
- Python Software Foundation. (s. f.-a). *time — Time access and conversions*. Python 3.12 documentation. <https://docs.python.org/3.12/library/time.html>
- Python Software Foundation. (s. f.-b). *tracemalloc — Trace memory allocations*. Python 3.12 documentation. <https://docs.python.org/3.12/library/tracemalloc.html>
- Ramalho, L. (2022). *Fluent Python: Clear, concise, and effective programming* (2.^a ed.). O'Reilly Media.
- Rice, S. A. (1925). The behavior of legislative groups: A method of measurement. *Political Science Quarterly*, 40(1), 60–72. <https://doi.org/10.2307/2142929>
- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell System Technical Journal*, 27(3), 379–423. <https://doi.org/10.1002/j.1538-7305.1948.tb01338.x>
- Toro-Maureira, S., Reutter, J., Valenzuela, L., Alcatruz, D., & Valenzuela, M. (2025). B-Call: Integrating ideological position and voting cohesion in legislative behavior. *Frontiers in Political Science*, 7, Artículo 1670089. <https://doi.org/10.3389/fpos.2025.1670089>

Anexo A · Corpus y universos de análisis

El corte congelado de F3 contiene 1.993 filas y 34 columnas. La matriz de 151 diputados por 15 votaciones tiene 2.265 celdas, de las cuales 272 no tienen registro. Estas celdas no se interpretan como abstención ni ausencia. Los distintos filtros responden al método y deben acompañar toda comparación.

Tabla N° 01. Los métodos conservan universos diferentes según información disponible

Método y unidad	Corpus	Incluidos	Excluidos	Votaciones
B-Call automático	151	136	15	13
B-Call con grupos externos	151	108	43	13
Posición por partido/votación	259	194	65	13
Posición agregada P_p	22	14	8	13
AI y entropía por celda	298	207	91	15
Rice por celda	298	204	94	15
Resumen de cohesión	23	14	9	15
Afinidad por pares	11325	9141	2184	15
Clustering	151	135	16	13
PCA/SVD	151	107	44	13

Elaboración propia en base a universo_por_metodo.csv; las unidades son diputados, partidos, celdas o pares según la primera columna. Los números no son directamente intercambiables.

Tabla N° 02. El conflicto informativo se concentra en trece decisiones

Bloque	Fecha	Votaciones	Interpretación
20627 y 20628	08-05-2023	2	Unánimes; excluidas del eje, conservadas en cohesión/afinidad
20629–20637	08-05-2023	9	Bloque predominante de disposiciones en disputa
21217–21219	08-05-2023	3	Artículo 32 y letras b/c del artículo 35
42724	26-08-2024	1	Comisión Mixta: 65 Sí, 22 No y 36 abstenciones

Elaboración propia en base a catalogo_votaciones.csv y F4_06. Catorce decisiones corresponden a una sola sesión: no permiten separar contenido de evolución temporal.

Afiliación histórica. Cada voto se agrega al partido vigente en su fecha. El escenario externo ignora registros independientes si existe una etiqueta partidaria consistente; quienes solo tienen registros independientes no reciben grupo externo. Sus votos sí pueden entrar al cálculo automático. Sin etiquetas externas hay 32 personas; otras 11 no superan su filtro de participación, por lo que el universo externo admite 108. No se descartan discrepancias con la referencia.

Anexo B · Modelos y métricas con reglas de interpretación

Tabla N° 03. Las métricas separan posición individual, posición partidaria y cohesión

Estimando y nivel	Fórmula y componentes	Regla y significado
B-Call d1 y d2 Diputado	$u_{ij}=s_j(x_{ij}-media_j)/SD_j$; $d1_i=\sum u_{ij}/m_i$; $d2_i=\sqrt{\sum(u_{ij}-d1_i)^2/(m_i-1)}$. $x \in \{-1,0,1\}$; s orienta; m cuenta decisiones utilizables.	SD muestral por votación; filtro >10 % sobre 15 columnas. d2 requiere ≥ 2 decisiones informativas; no representa una trayectoria temporal.
P_p Partido	$b_{pj}=\sum u_{ij}/n_{pj}$; $P_p=\sum b_{pj}/J_p$. n_{pj} cuenta integrantes con decisión; J_p cuenta celdas admitidas.	Al menos 2 decisiones por celda y 2 celdas. Igual peso entre votaciones; no equivale a promediar d1 con afiliación actual.
Agreement Index Partido/votación	$AI=[M-(T-M)/2]/T$; $M=\max(Y,N,A)$; $T=Y+N+A$.	Índice principal; incluye abstenciones. Con $T \geq 2$, valores 0–1; 1 es unanimidad. Mediana por partido.
Rice Partido/votación	$Rice= Y-N /(Y+N)$.	Contraste binario; exige $Y+N \geq 2$. Omite abstenciones, por lo que difiere de AI.
Cohesión entrópica Partido/votación	$CH=1-H/\ln(3)$; $H=-\sum q_k \ln(q_k)$; q_k es la proporción por opción. Se define $0 \ln(0)=0$.	Tres categorías. 1 es concentración total; 0, distribución equitativa. No se interpreta como posición.
Hamming y afinidad Par de diputados	$h_{ik}=\text{desacuerdos}/\text{covotos}$; $\text{afinidad}=1-h_{ik}$.	Nominal; solo decisiones compartidas, mínimo 2. Los faltantes no generan acuerdos.
PCA/SVD Diputado	$X \text{ centrada}=U\Sigma V^T$; $\text{coordenadas}=(X-\text{medias}) \cdot \text{cargas}$; $\lambda_k=\sigma_k^2/(n-1)$.	Sin escalamiento, casos completos y 13 columnas. Contraste descriptivo; el signo es arbitrario.
Clustering Diputado	Distancia Hamming nominal; enlace promedio, $k=2$.	Cobertura ≥ 80 % de columnas informativas. Se comparan grupos con ARI sobre universo común.

Elaboración propia en base a *bcall.py*, *posicion_partidos.py*, *cohesion.py*, *afinidad.py*, *pca_svd.py* y *agrupamiento.py*; fundamentos en Toro-Maureira et al. (2025), Hix et al. (2005), Rice (1925) y Shannon (1948).

Ejemplo aplicado de cohesión. Si una bancada registra $Y=3$, $N=1$ y $A=2$, entonces $T=6$ y $M=3$: $AI=(3-1,5)/6=0,25$, mientras $Rice=|3-1|/4=0,50$. La diferencia surge porque Rice no cuenta las dos abstenciones. Con $q=(1/2, 1/6, 1/3)$, $H \approx 1,011$ y $CH \approx 0,079$. El ejemplo ilustra fórmulas; no es una observación añadida al corpus.

Anexo C · Rendimiento y elección algorítmica

Tabla N° 04. La vectorización acelera la asignación temporal con salida equivalente

Escala	Votos	Iterativo s	Vectorizado s	Aceleración
1×	1.993	1,061622	0,008124	130,68×
5×	9.965	4,569059	0,023572	193,83×
10×	19.930	9,107840	0,044222	205,96×
100×	199.300	92,010762	0,578368	159,09×

Elaboración propia en base a F3_01_nucleo y al informe F3 (Grupo 1, 2026b). Medianas del entorno original; no son tiempos medidos al redactar este informe.

Tabla N° 05. El recorrido recursivo no presenta ventaja temporal consistente

Escala	Votos	Iterativo s	Recursivo s	Iterativo/recursivo
1×	1.993	0,013358	0,012082	1,106
5×	9.965	0,060787	0,060669	1,002
10×	19.930	0,118725	0,119445	0,994

Elaboración propia en base al benchmark de recorrido de F3_01_nucleo. Ambos métodos reciben nodos de ElementTree y comparten la conversión a fila.

Protocolo. Cinco repeticiones y una ejecución de calentamiento por escala; mediana, mínimo, máximo y desviación para tiempos; memoria Python medida por separado con tracemalloc. Las entradas y réplicas se preparan fuera de la sección cronometrada y sin llamadas de red. Los IDs sintéticos preservan unicidad y las implementaciones deben producir filas equivalentes y el mismo orden.

Decisión. La versión vectorizada se incorpora al flujo productivo porque reduce tiempo manteniendo significado y resultado. El recorrido iterativo de XML se conserva porque el recursivo no mejora de forma sostenida. ElementTree sigue siendo el parser; la comparación no enfrenta un parser con recursividad.

Tabla N° 06. La mejora empírica no elimina los límites de costo y memoria

Componente	Costo y límite	Consecuencia de diseño
Asignación iterativa	Hasta $O(NM)$ revisiones	Referencia funcional, alto sobre costo por fila
Asignación vectorizada	Cruce de C candidatos; filtro $O(C)$; C puede alcanzar NM	Controlar expansión de filas y memoria de candidatos
Recorrido directo	$O(n)$, salida $O(n)$	Elegido para la extracción productiva
Recursión por mitades	Profundidad $O(\log n)$; trabajo $O(n \log n)$ por copias/concatenación	No extrapolar beneficio desde profundidad reducida
Distancias entre diputados	$O(D^2V)$, matriz $O(D^2)$	El costo cuadrático requiere atención al ampliar el corpus

Elaboración propia en base al código. N =votos, M =militancias, C =candidatos, n =nodos, D =diputados y V =votaciones. tracemalloc no capta toda la memoria nativa de NumPy/pandas; no se afirma una reducción de memoria no medida.

Anexo D · Tablas complementarias de resultados

Tabla N° 07. La mayoría no combina votos Sí y No en sus decisiones observadas

Patrón individual	Diputados	Proporción aproximada
Misma opción en decisiones registradas	86	63 %
Un lado con alguna abstención	23	17 %
Combinan Sí y No	27	20 %

Elaboración propia en base a perfiles_voto.csv y F4_06; denominador de 136 diputados con d1, no una tasa de asistencia.

Tabla N° 08. Las diferencias entre índices son sustantivas en bancadas con disenso

Partido	Celdas AI	Mediana AI	Mediana Rice	Mediana C ^H
PDG	14	0,500	0,333	0,421
RN	15	0,559	0,500	0,409
UDI	15	0,917	1,000	0,805
EVOP	15	1,000	1,000	1,000
PREP	15	1,000	1,000	1,000
PC	15	1,000	1,000	1,000
PS	15	1,000	1,000	1,000

Elaboración propia en base a resumen_cohesion.csv. Selección de partidos para contraste; las medianas no son promedios ponderados por bancada.

Anexo E · Validación de modelos y sensibilidad

Tabla N° 09. La convergencia entre métodos convive con dependencia del bloque de disposiciones

Contraste	Resultado	Universo y cautela
Clustering frente a B-Call	ARI=1; 0 discrepancias	135 personas comunes; métodos sobre los mismos votos
PC1 alineada frente a d1	Pearson 0,999880; Spearman 0,998512	107 casos completos; no valida ideología externa
PCA varianza	PC1 85,70 %; PC2 7,24 %	13 columnas; centrado sin escalamiento
Cambio de pivote	25 de 25 conservan el eje	Pivotes elegibles de la referencia elegida
Retiro de una votación: d1	Máx. $ \Delta d1 =0,185$; 6 inversiones de signo	Omisión individual; no una serie temporal
Retiro de una votación: clustering	ARI mínimo 0,970	Comparación con grupos base en personas comunes
Retiro de bloque 20629–20637	ARI=0,461; 17 cambios	Se retiran 9 de 13 votaciones informativas
Cotejo externo	82,69 % de concordancia	1.479 filas diputado/votación; no personas únicas
Escenario sin PDG/Demócratas	84,37 % de concordancia	Universo externo reducido; no mejora de exactitud certificada
Cohesión sin unánimes	Δ mediana AI=0	Partidos comparables; no prueba independencia de agenda
Mínimo 3 decisiones por celda	4 cambios de admisibilidad	Las medianas comunes no cambian; sí cambia cobertura

Elaboración propia en base a *resumen_comparacion.csv*, *robustez_pivote.csv*, *sensibilidad.csv*, *sensibilidad_clustering.csv* y *F4_06*.

Contraste interno y referencia externa. ARI y correlaciones comparan soluciones construidas con los mismos votos: respaldan estructura interna, sin validar una ideología independiente. La referencia externa añade etiquetas partidarias y permite observar convergencias que atraviesan esa división, manteniendo discrepancias y exclusiones. El escenario externo vuelve a estandarizar y orientar sobre otro universo; sus puntajes no equivalen a recolorar el automático. La coincidencia de individuos no se extrapola a partidos completos.

Estabilidad del comportamiento frente a robustez. d2 describe variación entre votos de una persona; sensibilidad describe cambios de estimaciones ante otras decisiones metodológicas. Confundir ambas atribuiría al legislador una inestabilidad producida por cambiar la entrada del modelo. Los diseños mantienen o recalculan universos y documentan cuáles entran y salen.

Anexo F · Arquitectura y reproducción verificable

Tabla N° 10. Los contratos vinculan entradas con productores y salidas

Componente	Entrada	Salida y control
Extractores F2/F3	SOAP o XML crudo	CSV interim y modelos con esquema explícito
Transformador y validadores	Tablas interim	Tablas processed; claves, tipos, fechas, dominios
Integrador y asignadores	Votos y militancias históricas	Big table; OK/SIN_MILITANCIA/AMBIGUA
Codificación y matrices F4	Big table congelada	Vistas nominal/ternaria/binaria y máscara
Modelos y métricas	Matrices y afiliación por voto	Posiciones, cohesión, afinidad y exclusiones
Contratos/pipeline/exportación	Configuración y resultados	Salidas validadas y manifiesto con hashes

Elaboración propia en base a F2/src, F3/src/nucleo y F4/src/analisis.

Fragmento real del filtro temporal de asignar_vectorizado

```
vigente = (
    candidatos["fecha_inicio"].notna()
    & (candidatos["fecha_inicio"] <= candidatos["fecha"])
    & (candidatos["fecha_termino"].isna()
    | (candidatos["fecha"] <= candidatos["fecha_termino"]))
)
```

El cruce se realiza por diputado. La condición admite inicio y fin iguales a la fecha del voto y término abierto; después se exige exactamente una coincidencia. pandas permite comprobar cardinalidad en merge y conservar los diagnósticos (pandas development team, s. f.).

Ejecución desde la raíz del repositorio

```
uv sync --locked --group dev
uv run jupyter lab # F4_02 genera B-Call; F4_06 comunica los resultados
uv run python -m F4.src.analisis.pipeline # requiere salidas B-Call de F4_02
uv run pytest F2/test F3/test F4/test -m "not slow"
uv run pytest -m slow
```

Evidencia de CI de cierre. Ejecución 37213916565 sobre a83a09a, integrada en main 14070a5: 394 pruebas rápidas aprobadas (18,39 s), 48 pruebas de notebooks aprobadas (334,91 s), Ruff e identidad aprobados. Es un registro identificado del cierre técnico, distinto de la referencia documental aad911245e54; no se presenta como una nueva ejecución. El conteo no es porcentaje de cobertura y sus tiempos no son benchmarks de F3. Las pruebas verifican salidas en copias temporales con tolerancia numérica declarada.

Registro de CI verificado

Corte F3 SHA-256: 5bf21cbcb360da9074db00ac78de4ab53f2de3c061fa990618bfa4fc331433ef. Commit del corte: 022d4d0ac3d453430e1473ac603ef5ee0ca29d9f.

Anexo G · Trazabilidad y comunicación del proyecto

Tabla N° 11. Las mejoras vinculan necesidades con acciones e impacto técnico

Fecha	Observación	Acción	Commit	Impacto
27-09-2026	Costo por fila en asignación	Iterativo/vectorizado y equivalencia	c48250b	Aceleración sin cambiar afiliación histórica
27-09-2026	Comparación XML desconectada de extractor	Recorrido sobre nodos reales	3c88e96	Aísla recorrido y mantiene ElementTree
04-10-2026	SVD difiere en último decimal	Tolerancia relativa 1e-9	617a7f9	Comparación multiplataforma sin alterar textos/IDs
04-10-2026	IND no es partido homogéneo	No publicar P_p de IND	d0a56fb	Evita agregado partidario engañoso
04-10-2026	Títulos deben comunicar hallazgo	Títulos y cuatro frases	78d03a0	Figuras responden preguntas y declaran límites
04-10-2026	Rutas y esquemas dispersos	Contrato de datos	f7e0a4b	Productores, columnas y razones explícitos
04-10-2026	Dependencias y entrega verificable	Pipeline y manifiesto	9b38094	Validación secuencial y hashes de resultados

Elaboración propia en base al historial Git. Las necesidades de ingeniería no se atribuyen al profesor si no existe comentario formativo verificable; la recomendación sobre figuras sí corresponde a la comunicación docente proporcionada.

Commits verificables: c48250b · 3c88e96 · 617a7f9 · d0a56fb · 78d03a0 · f7e0a4b · 9b38094

Colaboración. En F3, Yerko desarrolló extracción y modelos; José Ignacio, validación e integración histórica; Sebastián, orquestación y mediciones. En F4 los responsables y revisores se registran en analisis.toml y las contribuciones/revisiones quedan en commits y PR. El cierre combina validación automática y revisión de equipo. No se usa el conteo de commits para inferir esfuerzo ni calidad individual.

Tabla N° 12. La comunicación audiovisual debe dedicar tiempo a evidencia y límites

Bloque	Tiempo orientativo	Contenido
Problema y preguntas	0:00–1:10	Portada, propósito, alcance y cuatro preguntas
Arquitectura y desarrollo	1:10–2:45	Flujo funcional, POO y mejora verificada
Corpus y resultados	2:45–6:50	Contexto, bloques, contraste externo, partidos y cohesión
Conclusiones y referencias	6:50–7:40	Hallazgos, límites y proyecciones

Elaboración propia en base al guion de notas de la PPT y a la pauta de 5–8 minutos; tiempos orientativos sujetos al ritmo de exposición.

Anexo H · Integración de fases arquitectura y decisiones de la solución

H.1. Aporte de cada fase al sistema final

La solución acumula capacidades: F2 construye la referencia funcional; F3 conserva sus resultados y fortalece el núcleo; F4 utiliza esa entrada validada para responder las preguntas de F1. El informe sintetiza esas relaciones y el repositorio conserva el detalle de implementación.

Tabla N° 13. Cada fase aporta una capacidad verificable a la solución integrada


Fase	Aporte y decisión estructural	Artefactos de evidencia
F1	Define problema, P1–P4, alcance y entorno. Las preguntas permanecen como criterio para seleccionar métricas y figuras.	F1/notebooks/F1_Definición.ipynb; pyproject.toml; uv.lock
F2	Obtiene fuentes oficiales, explora calidad, normaliza e integra militancias por fecha. Establece la referencia de resultados.	F2_01–04; F2/src; datos raw/interim/processed y pruebas
F3	Refactoriza con objetos y validadores, verifica equivalencia y compara estrategias sobre entradas comunes. Selecciona vectorización e iteración XML por evidencia.	F3_01_nucleo; F3/src/nucleo; reportes de calidad y benchmarks
F4	Construye matrices, declara universos, estima posiciones y cohesión, contrasta métodos y comunica las cuatro respuestas.	F4_01–06; analisis.toml; contratos.py; pipeline.py; resultados y manifiestos

Elaboración propia en base a los notebooks, módulos, pruebas y contratos de F1–F4; Grupo 1 (2026a, 2026b, 2026c).

Criterio de integración. Los cambios de ingeniería se aceptan con equivalencia de resultados; las decisiones analíticas se interpretan con su universo y límite. El control técnico permite rastrear la evidencia, mientras el contenido de las disposiciones define su alcance político.

H.2. Arquitectura funcional y flujo operacional

Imagen N° 06. Las fuentes oficiales se transforman en evidencia con controles entre etapas



Elaboración propia en base a *ExtractorBase*, *TransformadorDataset*, *construir_big_table*, *matrices.py*, *pipeline.py* y *contratos.py*.

Qué muestra. El flujo desde SOAP/XML hasta análisis y comunicación, con ramas para personas, partidos y robustez.


Qué infiero. La misma entrada validada sostiene las cuatro respuestas, con controles que permiten rastrear cada transformación.

Qué límite tiene. El pipeline de F4 requiere las salidas B-Call de F4_02; la figura no representa un único comando que reemplace todos los notebooks.

Cómo aporta al relato. Integra el proceso de F1–F4 y sitúa las decisiones que preservan significado y reproducibilidad.

H.3. Dependencias y aplicación de POO en el núcleo

Imagen N° 07. Interfaces compartidas y responsabilidades separadas organizan el núcleo



Elaboración propia en base a F3/src/nucleo/extractores.py, modelos.py, transformador_dataset.py, integrador_dataset.py y las clases analíticas de F4.

Qué muestra. Contratos base, herencia y relaciones de uso o flujo; las flechas de herencia apuntan a la interfaz base. El diagrama agrupa componentes, sin enumerar todas las clases.

Qué infiero. Template Method reutiliza la extracción; los objetos de valor controlan registros interim; validadores y transformadores separan responsabilidades. Los asignadores son funciones intercambiables y el procesamiento masivo utiliza DataFrames.

Qué límite tiene. Las fuentes con múltiples respuestas especializan la plantilla; ampliar sus ganchos es una mejora futura. La modularidad no elimina el costo del cruce temporal ni de las distancias.

Cómo aporta al relato. Vincula la POO de F3 con el análisis de F4 y muestra qué debe declarar una extensión: consulta, parseo y contrato para una fuente; entradas, universo y salidas para un análisis.

H.4. Decisiones relevantes y consecuencias analíticas

Tabla N° 14. Las decisiones preservan el significado del dato y acotan la interpretación

Decisión	Fundamento	Consecuencia y evidencia
Conservar XML y capas raw/interim/processed	Separar fuente original, representación validada y dataset analítico.	Reprocesamiento sin red y rastreo de transformaciones; extractores y validadores F3.
Militancia vigente a la fecha del voto	Las afiliaciones cambian durante el período.	Evita reasignación retrospectiva; intervalos cerrados, término abierto y diagnósticos OK/SIN_MILITANCIA/AMBIGUA.
NA distinto de abstención	Falta de registro no acredita ausencia y no es una decisión nominal.	272 celdas permanecen NA; máscara de observación; no imputación ni acuerdos ficticios.
Tres vistas del voto	Los métodos requieren categorías o valores numéricos diferentes.	Nominal para acuerdos; ternaria para B-Call/PCA; binaria conserva abstención como NA.
Universo específico por método	Varianza, participación y completitud afectan estimabilidad.	136 d1 / 135 planos; 108 externos / 107 planos; PCA 107 y clustering 135; comparar personas comunes.
Eje automático y referencia externa separados	Agrupar desde votos y contrastar etiquetas son operaciones distintas.	Conservar discrepancias; externo recalcula puntajes; proximidad no demuestra cambio ideológico.
Posición partidaria con doble agregación	Primero integrantes por votación; después igual peso de votaciones admitidas.	P _p no equivale a mediana d1; leer RIQ y cohesión; mínimos de publicación e IND excluido como partido.
Cohesión con indicadores complementarios	Rice omite abstenciones y las medianas pueden ocultar episodios.	Combinar AI, Rice, entropía y desacuerdo intrapartido; UDI y EVOP ilustran diferencias.
Equivalencia antes de optimizar	Reducir tiempo exige conservar salida y significado.	F2/F3 equivalentes; vectorización seleccionada por benchmarks; XML iterativo sin ventaja recursiva sostenida.
Sensibilidad y alcance descriptivo	Los modelos comparten información y dependen de la agenda.	Convergencia interna; retiro del bloque altera grupos; no causalidad ni generalización ideológica.

Elaboración propia en base a *analysis.toml*, *decisiones_metodologicas.json*, *contratos.py*, *F3_01* y *F4_01-06*; detalle en Anexos A–F.

H.5. Relación entre preguntas resultados y evidencia

Tabla N° 15. Cada respuesta conserva su nivel de análisis y su límite

Pregunta y nivel	Resultado e interpretación	Evidencia y límite
P1 · Personas	Dos alineamientos predominantes; algunos diputados de derecha comparten patrones con la izquierda según referencia externa.	d1 y perfiles; Imágenes 02–03; F4_02/F4_06. No clasifica ideología permanente ni partidos completos.
P2 · Personas	Consistencia frecuente y variabilidad entre disposiciones; las posiciones intermedias suelen combinar Sí y No.	d2 y perfiles; Anexo D; F4_02/F4_06. Catorce decisiones en una sesión impiden una trayectoria temporal.
P3 · Partidos	El centro agregado de RN/PDG reúne posiciones contrapuestas; no demuestra moderación compartida.	P_p, mediana y RIQ; Imagen 04; F4_03/F4_06. Depende de composición histórica y votaciones admitidas.
P4 · Partidos	Unidad frecuente con disenso desigual; abstenciones y episodios puntuales exigen combinar indicadores.	AI, Rice, entropía y Hamming intrapartido; Imagen 05; F4_05/F4_06. No demuestra disciplina impuesta.

Elaboración propia en base a las preguntas originales de F1, las salidas de F4 y las interpretaciones de las figuras de resultados.

Localización de detalle. El lector puede seguir P1/P2 en F4_02, P3 y afinidad en F4_03, contrastes en F4_04, P4 en F4_05 y la integración de respuestas en F4_06. F4_01 audita el punto de partida; F3_01 documenta construcción y rendimiento. Así, el informe conserva la explicación de la solución y sus decisiones, mientras los notebooks, módulos y pruebas permiten verificar los resultados.